



Université de Nouakchott
Faculté des Sciences et Techniques

Bases de données semi-structurées
Langage XML

M1S1-Informatique

Mohamed Lamine Diakité

Année Universitaire 2025-2026

Références bibliographiques

- ✓ XML IN A NUTSHELL, 2éme Edition, *Manuel de référence, Elliotte Rusty Harold & W. Scott Means, Editions O'Reilly*
- ✓ L'essentiel de XML: Cours XML; Support de cours de Olivier Carton
Université de Paris Diderot

Plan

1. Introduction à XML
2. Notion de document
3. DTD
4. Espaces de noms
5. XML Schema
6. Outils de validation
7. Xpath (*Langage de requête pour extraire des portions de doc XML*)
8. Xquery (*Langage de requête pour extraire des informations*)
9. XSLT (*eXtensible Stylesheet Language Transformations*)

I. Introduction à XML

- ✓ Le développement du web s'est accompagné de l'accroissement des données semi-structurées
- ✓ Elles sont très nombreuses sur le Web
- ✓ Elles sont complexes, hétérogènes, incomplètes, ...
- ✓ Sont difficilement supportées par les BDD relationnelles

I. Introduction à XML

- ✓ **Les données structurées** sont des données organisées et formatées que l'on peut mettre dans des tableaux et des feuilles de calcul (BDD, entrepôt de données).
- ✓ **Les données semi-structurées** font référence à des données qui ne suivent pas un schéma fixe et un format défini comme dans les bases de données relationnelles
- ✓ Elles contiennent quelques propriétés organisationnelles : *des balises, des métadonnées ou des tags, etc* qui les rendent plus faciles à traiter, organiser et manipuler que les données **non structurées**.
- ✓ **Les données non structurées** : *les documents texte, les vidéos ou les images*, nécessitent des techniques plus sophistiquées, comme le traitement du langage naturel ou la reconnaissance d'images, pour extraire des informations utiles.
- ✓ **Le langage XML** se présente comme le standard le plus adapté pour manipuler des données semi-structurées en offrant la possibilité d'annoter des informations sans pour autant passer par un schéma structuré et contraignant.

I. Introduction à XML

XML est un langage d'expression pour les données semi-structurées. Il est composé :

- ✓ d'objets complexes (ensemble d'objets complexes et atomiques)
- ✓ d'objets atomiques (chaîne, nombre, ...)
- ✓ d'attributs

I. Introduction à XML

- XML= eXtensible Markup Language
- XML est un langage pour structurer des contenus et définir une classe d'objets de données
- XML est un métalangage à balises : pas de jeux de balises prédéfinies et d'éléments supposés fonctionner pour tout le monde
- Le langage est basé sur le concept de balisage des données
- Un document XML:

contient des déclarations, éléments, commentaires, définition de caractères spéciaux et instructions (facultatives) de traitement

I. Introduction à XML

- c'est un arbre: il doit avoir une racine et les éléments doivent s'imbriquer proprement
- Plus performant que HTML
- Recommandation officielle du [W3C \(World Wide Web Consortium\)](#) depuis le 10 février 1998
- Idéal pour l'échange de données semi-structurées
- Utilisable entre machines

W3C (World Wide Web Consortium)

Fondateur : Tim Berners-Lee

Organisme de standardisation à but non lucratif fondé en 1994. Il est chargé de promouvoir la compatibilité des technologies du WWW telles que HTML5, HTML, XHTML, XML, RDF, etc.

I. Introduction à XML

- XML, c'est donc :
 - un métalangage universel pour structurer les données
 - qui permet aux utilisateurs de délivrer du contenu
 - depuis les applications à d'autres applications
- XML est un moyen de standardiser la manière dont l'information est :
 - échangée (XML)
 - personnalisée/présentée (XSL/CSS)
 - recherchée (XPath/XSLT/XQuery)
 - sécurisée (Encryption, Signature)
 - liée (XLink)

I. Introduction à XML

- Balise (ou tag ou label)
 - marque de début et fin permettant de repérer un élément de données (textuel)
 - forme: <balise> de début, </balise> de fin
 - les balises indiquent la signification des sections marquées
- Élément de données
 - texte encadré par une balise de début et une balise de fin
 - les éléments de données peuvent être imbriqués
- Attribut
 - couple nom="valeur" qualifiant une balise
 - <producteur no="160017" region="Bourgogne"/>

I. Introduction à XML

- Les utilisateurs définissent leurs propres balises
- Il est possible d'imposer une grammaire spécifique (DTD, Schéma)

I. Introduction à XML

En résumé, XML :

- Permet de faciliter les échanges de données entre les machines et les logiciels;
- Est un langage qui s'écrit à l'aide des balises;
- Est une recommandation du W3C (règles à respecter);
- Compréhensible par les hommes et les machines;
- Permet de créer notre propre vocabulaire grâce à un ensemble de règles et de balises personnalisables.

I. Introduction à XML


Exemple: Document XML

```
<?xml version="1.0"?>
<!-- Ma Bibliotheque-->
<Bibliotheque>
  <Livre id="Li001">
    <Titre>BDD Relationnelles</Titre>
    <Auteur>G. Gardarin</Auteur>
    <Annee>2004</Annee>
    <Editeur>Eyrolles</Editeur>
  </Livre>
</Bibliotheque>
```

Corps du document


I. Introduction à XML

Exemple: Document XML




I. Introduction à XML

Exemple: Document XML



I. Introduction à XML

- Le format interne d'un document XML est un arbre



I. Introduction à XML

Quelques outils (éditeurs)

- NotePad++
- EditiX (version gratuite et payante)
- <oXygen/> XML Editor (version payante et essai de 30 jours)


II. Document XML

- Un document XML comprend 2 parties :

1. Le prologue



2. Le corps du document



Document XML

II. Document XML

1. **Le Prologue** : contient 2 déclarations facultatives mais fortement conseillées + des instructions de traitement et des commentaires

- l'entête XML de la forme



```
<?xml version="1.0" ...?>
```

- La Déclaration du Type de Document (DTD)



```
<!DOCTYPE Racine-Document [  
...  

```

- Les instructions de traitement et les commentaires peuvent apparaître partout dans le document.

Note : La DTD peut être omise lorsqu'on utilise d'autres modèles remplaçant les DTD (ex. **schéma XML**...)

II. Document XML

- **L'entête XML** : précise la version de XML et le codage du fichier entre autres
- Doit se trouver au tout début du document

```
<?xml version="..." encoding="..." standalone="..."?>
```

Indique la version XML utilisée
(1.0; 1.1; 2.0; etc.)

Indique si le fichier est autonome, c'est-à-dire
s'il existe des **déclarations externes** qui
affectent le document (yes; no)

Précise le codage utilisé dans
le fichier. Principales valeurs :
US-ASCII, ISO-8859-1, UTF-8, et UTF-16

DTD ou autres paramètres...

Exemple

```
<?xml version="1.0" encoding="UTF-8"?>
```

```
<?xml version="1.1" encoding="iso-8859-1"?>
```

```
<?xml version='2.0' encoding="iso-8859-1" standalone='yes'?>
```

II. Document XML

- La DTD (Document Type Definition) : permet de définir la structure d'un document.
- Un ensemble de contraintes que doit respecter un document pour être valide.
- Elle précise en particulier quels éléments peut contenir chacun des éléments, l'ordre des éléments, etc.
- Elle peut être interne au document , externe ou mixte.

A voir plus loin...

II. Document XML

2. Le Corps du document : contenu organisé de façon hiérarchique

- **Élément** : L'unité de cette organisation

- Un élément peut contenir :

- du texte;
- d'autres éléments
- ou texte + éléments

```
<RacineDocument>
...
  <NomElement1> Contenu de l'élément 1 </NomElement1>
...
  <NomElementn> Contenu de l'élément n</NomElementn>
...
</RacineDocument>
```

`<NomElement> Contenu de l'élément </NomElement>`



Balise ouvrante



Balise fermante

Ne peut pas contenir d'espace



`<NomElement>`


Ne doit pas avoir d'espace

`<NomElement> </NomElement>` ↔ `<NomElement/>`


Élément vide Balises contractées

II. Document XML

- Imbrication des éléments si contenu en commun



```
<parent>
  <sibling1> ... </sibling1>
  <sibling2> ... </sibling2>
  <self>
    <child1> ... <desc1></desc1> ... <desc2></desc2> ... </child1>
    <child2> ... </child2>
    <child3> ... <desc3><desc4> ... </desc4></desc3> ... </child3>
  </self>
  <sibling3> ... </sibling3>
</parent>
```



Exemple de représentation de liens de parenté
(tiré de L'essentiel de XML: Cours XML Olivier Carton)

II. Document XML

- Le corps du document se trouve dans le contenu de l'élément racine (**unique**)
- Les balises ouvrantes peuvent contenir des attributs associés à des valeurs

```
<NomElement Attribut1="valeur1"  
            Attribut2="Valeur2"...>  
    Contenu de l'élément  
</NomElement>
```

- Possibilité de mettre des attributs et les valeurs associées dans la balise dont l'élément est vide (*balises ouvrante et fermante contractées*)


```
<NomElement Attribut1='valeur1'  
            Attribut2='Valeur2'... />
```

- **Les sections littérales**: Les caractères spéciaux '<', '>' et '&' ne peuvent pas être inclus directement dans le contenu d'un document. Ils peuvent être inclus par l'intermédiaire des entités prédéfinies.

<![CDATA[Contenu avec des caractères spéciaux <, > et &**]]>**

Exemple: Caractères spéciaux

```
<?xml version = "1.0" encoding="UTF-8" standalone="yes" ?>
<repertoire>
  <CaractSpeciaux>caractères spéciaux <![CDATA[<, > et &]]></CaractSpeciaux>
</repertoire>
```



II. Document XML

Attributs particuliers

- L'attribut **xml:lang** est utilisé pour décrire la langue du contenu de l'élément. Sa valeur est un code de langue sur deux ou trois lettres de la norme ISO 639 [W] (comme par exemple en, fr, es, de, it, pt, **MR** ...).
- Ce code peut être suivi d'un code de pays sur deux lettres de la norme **ISO 3166** [W] séparé du code de langue par un caractère tiret '-'

```
<p xml:lang="fr">Bonjour</p>
```

```
<p xml:lang="en-GB">Hello</p>
```

```
<p xml:lang="en-US">Hi</p>
```

Codes pour la représentation des noms de pays et de leurs subdivisions

```

<?xml version="1.0" encoding="iso-8859-1"?>
<!-- Time-stamp: "bibliography.xml 3 Mar 2008 16:24:04" -->
<bibliography>
  <book key="Michard01" lang="fr">
    <title>XML langage et applications</title>
    <author>Alain Michard</author>
    <year>2001</year>
    <publisher>Eyrolles</publisher>
    <isbn>2-212-09206-7</isbn>
    <url>http://www.editions-eyrolles/livres/michard/</url>
  </book>
  <book key="Zeldman03" lang="en">
    <title>Designing with web standards</title>
    <author>Jeffrey Zeldman</author>
    <year>2003</year>
    <publisher>New Riders</publisher>
    <isbn>0-7357-1201-8</isbn>
  </book>
</bibliography>

```

III. Document Type Definition (DTD)

- Une **DTD** = ensemble de contraintes que doit respecter un document pour être valide
- La déclaration d'une **DTD** doit être faite dans le prologue
- Une **DTD** peut être interne, externe au document ou mixte.

```
<?xml version = "1.0" encoding="UTF-8" standalone="yes" ?>  
  
<!DOCTYPE bibliography ... >  
<bibliography>  
    ...  
</bibliography>
```

A curly bracket is drawn under the '...' in the DTD declaration line, pointing to the '...' in the root element's closing tag, indicating that the root element must conform to the constraints defined in the DTD.

Le nom de l'élément racine est suivi du contenu de la DTD dans le cas d'une DTD interne ou de l'URL du fichier contenant la DTD dans le cas d'une DTD externe.

III. Document Type Definition (DTD)

DTD interne

Lorsque la DTD est incluse dans le document, sa déclaration prend la forme suivante où son contenu est encadré par des caractères crochets '[' et ']'.

<!DOCTYPE root-element [declarations]>

Exemple de déclaration:

```
<!DOCTYPE simple [  
    <!ELEMENT simple (#PCDATA)>  
]>
```

Le nom de l'élément racine est **simple**. La DTD déclare que cet élément ne peut contenir que du texte (**Parsed Characters DATA**) et pas d'autre élément.

III. Document Type Definition (DTD)

DTD externe

- Une DTD est externe est contenue dans un autre fichier dont l'extension est généralement **.dtd**.
- Il faut alors préciser dans le document XML l'adresse de sa DTD pour que les logiciels puissent y accéder.
- L'adresse de la DTD peut être donnée explicitement par une **URL** ou par un **FPI (Formal Public Identifier)**.

- Référence à une **URL** (Uniform Resource Locator) :
<!DOCTYPE root-element SYSTEM "URL">

**<!DOCTYPE bibliography SYSTEM
"http://www.omega-one.org/~carton/Enseignement/bibliography.dtd">**

<!DOCTYPE bibliography SYSTEM "bibliography.dtd">

- Peut aussi être sous forme **ftp://...**

III. Document Type Definition (DTD)

Exemple

Bibliography.dtd

```
<!ELEMENT bibliography (book)+>
<!ELEMENT book (title, author, year, publisher, isbn, url?)>
<!ATTLIST book key NMTOKEN #REQUIRED>
<!ATTLIST book lang (fr | en) #REQUIRED>
<!ELEMENT title (#PCDATA)>
<!ELEMENT author (#PCDATA)>
<!ELEMENT year (#PCDATA)>
<!ELEMENT publisher (#PCDATA)>
<!ELEMENT isbn (#PCDATA)>
<!ELEMENT url (#PCDATA)>
```

bibliography.xml

```
<?xml version="1.0" encoding="iso-8859-1" standalone="yes"?>
<!-- Time-stamp: "bibliography.xml 3 Mar 2008 16:24:04" -->
<!DOCTYPE bibliography SYSTEM "Bibliography.dtd">
<bibliography>
  <book key="Michard01" lang="fr">
    <title>XML language et applications</title>
    <author>Alain Michard</author>
    <year>2001</year>
    <publisher>Eyrolles</publisher>
    <isbn>2-212-09206-7</isbn>
    <url>http://www.editions-eyrolles/livres/michard</url>
  </book>
  <book key="Zeldman03" lang="en">
    <title>Designing with web standards</title>
    <author>Jeffrey Zeldman</author>
    <year>2003</year>
    <publisher>New Riders</publisher>
    <isbn>0-7357-1201-8</isbn>
  </book>
</bibliography>
```


III. Document Type Definition (DTD)

DTD mixte

- Il est possible d'avoir simultanément une DTD externe adressée par URL et des déclarations internes.
- La DTD globale est alors formée des déclarations externes suivies des déclarations internes .
- On retrouve un mélange de la syntaxe des DTD externes avec les mots clés **SYSTEM** et de la syntaxe des DTD internes avec des déclarations encadrées par les caractères '[' et ']'.

<!DOCTYPE root-element SYSTEM "URL" [declarations]>

III. Document Type Definition (DTD)

Contenu d'une DTD

- Une DTD est constituée de déclarations d'éléments, d'attributs et d'entités.
- Chacune de ces déclarations commence par la chaîne '<!' suivi d'un mot clé qui indique le type de déclaration.
- Les mots clés possibles sont **ELEMENT**, **ATTLIST** et **ENTITY**.
- La déclaration se termine par le caractère '>'

III. Document Type Definition (DTD)

✓ Commentaires

- Les commentaires sont délimités par '`<!--`' et '`-->`'
- Ils sont placés au même niveau que les déclarations d'éléments, d'attributs et d'entités.
- Ils ne peuvent pas apparaître à l'intérieur d'une déclaration.

Exemple : `<!-- DTD pour les bibliographies -->`

✓ Entités

- Une entité est, en quelque sorte, un nom donné à un fragment de document.
- Le fragment peut être donné explicitement à la définition de l'entité dans la DTD.
- Il peut également provenir d'un fichier externe.
 - Entités générales destinées à être utilisées dans le corps du document XML
 - Entités paramètres utilisées dans la DTD

III. Document Type Definition (DTD)

- La déclaration d'une entité :

`<!ENTITY Name "fragment">`  Interne

`<!ENTITY Name SYSTEM "URL">`  Externe

- Une entité de nom **Name** peut être référencée par **&Name;**
- Une entité interne peut être référencée dans les valeurs d'attributs ou les contenus d'éléments

`<tag meta="attribute: &Name;">Content: &Name;</tag>`

- Une entité externe ne peut être référencée que dans les contenus d'éléments

`<tag >Content: &Name;</tag>`

III. Document Type Definition (DTD)


- **Entités internes** : La valeur d'une entité interne est le fragment de document associé à celle-ci lors de sa déclaration. Cette valeur peut contenir des caractères ainsi que des éléments avec leurs balises

```

<?xml version="1.0" encoding="iso-8859-1" standalone="yes"?>
<!-- Time-stamp: "bibliography.xml 3 Mar 2008 16:24:04" -->
<!DOCTYPE bibliography SYSTEM "Bibliography.dtd"
[
  <!ENTITY Element '<year>2001</year>'>
  <!ENTITY Attribut 'Michard01'>
  <!ENTITY ElemContenu 'Eyrolles'>]
>
<bibliography>
  <book key="&Attribut;">
    <title>XML langage et applications</title>
    <author>Alain Michard</author>
    &Element;
    <publisher>&ElemContenu;</publisher>
    <isbn>2-212-09206-7</isbn>
    <url>http://www.editions-eyrolles/livres/michard/</url>
  </book>
  <book key="Zeldman03" lang="en">
    <title>Designing with web standards</title>
    <author>Jeffrey Zeldman</author>
    <year>2003</year>
    <publisher>New Riders</publisher>
    <isbn>0-7357-1201-8</isbn>
  </book>
</bibliography>

```

```
[<!ENTITY Element '<year>2001</year>'  
<!ENTITY Attribut 'Michard01'>  
<!ENTITY ElemContenu 'Eyrolles'>]
```




```
<bibliography>  
  <book key="&Attribut;">  
    <title>XML langage et applications</title>  
    <author>Alain Michard</author>  
    &Element;  
    <publisher>&ElemContenu;</publisher>
```

```
-<!--  
  Time-stamp: "bibliography.xml  3 Mar 2008 16:24:04"  
-->  
-<bibliography>  
  -<book key="Michard01">  
    <title>XML langage et applications</title>  
    <author>Alain Michard</author>  
    <year>2001</year>  
    <publisher>Eyrolles</publisher>  
    <isbn>2-212-09206-7</isbn>  
    <url>http://www.editions-eyrolles/livres/michard/</url>  
  </book>  
  -<book key="Zeldman03" lang="en">  
    <title>Designing with web standards</title>  
    <author>Jeffrey Zeldman</author>  
    <year>2003</year>  
    <publisher>New Riders</publisher>  
    <isbn>0-7357-1201-8</isbn>  
  </book>  
</bibliography>
```



```
[<!ENTITY Element '<year>2001</year>']>
<!ENTITY Attribut 'Michard01'>
<!ENTITY ElemContenu 'Eyrolles'>]
```




```
<bibliography>
<book key="&Attribut;">
  <title>XML langage et applications</title>
  <author>Alain Michard</author>
  &Element;
  <publisher>&ElemContenu;</publisher>
```

```
-<!--
  Time-stamp: "bibliography.xml  3 Mar 2008 16:24:04"
-->
-<bibliography>
  -<book key="Michard01">
    <title>XML langage et applications</title>
    <author>Alain Michard</author>
    <year>2001</year>
    <publisher>Eyrolles</publisher>
    <isbn>2-212-09206-7</isbn>
    <url>http://www.editions-eyrolles/livres/michard/</url>
  </book>
  -<book key="Zeldman03" lang="en">
    <title>Designing with web standards</title>
    <author>Jeffrey Zeldman</author>
    <year>2003</year>
    <publisher>New Riders</publisher>
    <isbn>0-7357-1201-8</isbn>
  </book>
</bibliography>
```



```
[<!ENTITY Element '<year>2001</year>'\>
<!ENTITY Attribut 'Michard01'\>
<!ENTITY ElemContenu 'Eyrolles'\>]
```



```
<bibliography>
  <book key="&Attribut;">
    <title>XML langage et applications</title>
    <author>Alain Michard</author>
    &Element;
    <publisher>&ElemContenu;</publisher>
```

```
-<!--
  Time-stamp: "bibliography.xml  3 Mar 2008 16:24:04"
-->
-<bibliography>
  -<book key="Michard01">
    <title>XML langage et applications</title>
    <author>Alain Michard</author>
    <year>2001</year>
    <publisher>Eyrolles</publisher>
    <isbn>2-212-09206-7</isbn>
    <url>http://www.editions-eyrolles/livres/michard/</url>
  </book>
  -<book key="Zeldman03" lang="en">
    <title>Designing with web standards</title>
    <author>Jeffrey Zeldman</author>
    <year>2003</year>
    <publisher>New Riders</publisher>
    <isbn>0-7357-1201-8</isbn>
  </book>
</bibliography>
```

III. Document Type Definition (DTD)

- **Entités externes:** Une entité peut désigner un fragment de document contenu dans un autre fichier. Ce mécanisme permet de répartir un même document sur plusieurs fichiers.

Exemple

```

<?xml version="1.0" encoding="utf-8" standalone="no"?>
<!-- Entites externes -->
<!DOCTYPE bibliography
[
  <!ENTITY Book1 SYSTEM "Book1.xml">
  <!ENTITY Book2 SYSTEM "Book2.xml">
]>
<bibliography>
  &Book1;
  &Book2;
</bibliography>

```

Book1.xml

```

<?xml version="1.0" encoding="utf-8"?>
<book key='Michard01'>
  <title>XML langage et applications</title>
  <author>Alain Michard</author>
  <year>2001</year>
  <publisher>Eyrolles</publisher>
  <isbn>2-212-09206-7</isbn>
  <url>http://www.editions-eyrolles/livres/michard/</url>
</book>

```

Book2.xml

```

<?xml version="1.0" encoding="utf-8"?>
<book key="Zeldman03" lang="en">
  <title>Designing with web standards</title>
  <author>Jeffrey Zeldman</author>
  <year>2003</year>
  <publisher>New Riders</publisher>
  <isbn>0-7357-1201-8</isbn>
</book>

```

III. Document Type Definition (DTD)

➤ **Entités paramètres** : Une entité qui ne peut être utilisée qu'à l'intérieur d'une DTD

`<!ENTITY % Name "fragment">` —————> Interne

`<!ENTITY % Name SYSTEM "URL">` —————> Externe

- Une entité de nom **Name** peut être référencée par **%Name;**
- Une entité interne peut être référencée dans les déclarations d'éléments, d'attributs ou d'autres entités.
- Lorsque l'entité est externe, elle est utilisée en dehors des déclarations pour inclure des déclarations provenant du document référencé par l'entité.

III. Document Type Definition (DTD)

Définition de deux entités paramètres **idatt** et **langatt** permettant de déclarer des attributs **id** et **xml:lang**

<!-- Déclaration de deux entités paramètres -->

<!ENTITY % idatt "id ID #REQUIRED">

<!ENTITY % langatt "xml:lang NMTOKEN 'fr'">

<!-- Utilisation des deux entités paramètres -->

<!ATTLIST chapter %idatt; %langatt;>

<!ATTLIST section %langatt;>



**<!ATTLIST chapter id ID #REQUIRED
xml:lang NMTOKEN 'fr'>**
<!ATTLIST section xml:lang NMTOKEN 'fr'>

III. Document Type Definition (DTD)

Les entités externes permettent d'inclure une partie de DTD provenant d'un document externe

<!-- Entité paramètre pour inclure la DTD principale -->

<!ENTITY % main SYSTEM "main.dtd">

<!-- Inclusion du fichier main.dtd -->

%main;

III. Document Type Definition (DTD)

Entités prédéfinies

Entité	Caractère
<	<
>	>
&	&
'	'
"	"

- Les trois entités <, > et & doivent être utilisées aussi bien dans le contenu des éléments que dans les valeurs des attributs puisque les caractères '<', '>' et '&' ne peuvent pas y apparaître directement.
- Les deux entités ' et " sont uniquement nécessaires pour inclure le caractère "'" ou le caractère '"' dans la valeur d'un attribut délimitée par le même caractère.

III. Document Type Definition (DTD)

✓ Elements

- La déclaration d'éléments permet de spécifier quels sont les enfants de chaque élément et l'ordre de ces enfants.
- La déclaration d'un élément précise **le nom** et **le type de l'élément**.
- Le nom de l'élément doit être un nom XML
- Le type détermine les contenus valides de l'élément
 - **Contenus purs** uniquement constitués d'autres éléments
 - **Contenus textuels** uniquement constitués de texte et les contenus mixtes (éléments et texte)

Déclaration d'un élément

<!ELEMENT element type>

III. Document Type Definition (DTD)

- **Contenu pur d'éléments** : ne contient aucun texte mais uniquement d'éléments

<!ELEMENT element *expr*>

- ✓ L'expression rationnelle *expr* décrit les suites autorisées d'enfants dans le contenu de l'élément
- ✓ Cette expression rationnelle est construite à partir des noms d'éléments en utilisant les opérateurs ',', '|', '?', '*' et '+' ainsi que les parenthèses '(' et ')' pour former des groupes
- ✓ Les opérateurs ',', '|' et '|' sont binaires alors que les opérateurs '?', '*' et '+' sont unaires et postfixés

III. Document Type Definition (DTD)

➤ **Contenu pur d'éléments** : ne contient aucun texte mais uniquement d'éléments

Opérateur	Signification
,	Mise en séquence
	Choix
?	0 ou 1 occurrence
*	Répétition d'un nombre quelconque d'occurrences
+	Répétition d'un nombre non nul d'occurrences

Exemple

`<!ELEMENT elem (elem1, elem2, elem3)>`

L'élément `elem` doit contenir un élément `elem1`, un élément `elem2` puis un élément `elem3` dans cet ordre.

`<!ELEMENT elem (elem1 | elem2 | elem3)>`

L'élément `elem` doit contenir un seul des éléments `elem1`, `elem2` ou `elem3`.

`<!ELEMENT elem (elem1, elem2?, elem3)>`

L'élément `elem` doit contenir un élément `elem1`, un ou zéro élément `elem2` puis un élément `elem3` dans cet ordre.

`<!ELEMENT elem (elem1, elem2*, elem3)>`

L'élément `elem` doit contenir un élément `elem1`, une suite éventuellement vide d'éléments `elem2` et un élément `elem3` dans cet ordre.

`<!ELEMENT elem (elem1, (elem2 | elem4), elem3)>`

L'élément `elem` doit contenir un élément `elem1`, un élément `elem2` ou un élément `elem4` puis un élément `elem3` dans cet ordre.

`<!ELEMENT elem (elem1, elem2, elem3)*>`

L'élément `elem` doit contenir une suite d'éléments `elem1`, `elem2`, `elem3`, `elem1`, `elem2`, ... jusqu'à un élément `elem3`.

`<!ELEMENT elem (elem1 | elem2 | elem3)*>`

L'élément `elem` doit contenir une suite quelconque d'éléments `elem1`, `elem2` ou `elem3`.

`<!ELEMENT elem (elem1 | elem2 | elem3)+>`

L'élément `elem` doit contenir une suite non vide d'éléments `elem1`, `elem2` ou `elem3`.

III. Document Type Definition (DTD)

➤ Contenu textuel

Un élément dont le contenu est textuel

<!ELEMENT element (#PCDATA)>

➤ Contenu mixte : texte et des éléments

Il n'y a aucun contrôle sur le nombre d'occurrences de chacun des éléments et sur leur ordre d'apparition dans le contenu de l'élément.

Le mot clé #PCDATA doit apparaître en premier avant tous les noms des éléments.

<!ELEMENT element (#PCDATA | element1 | ... | elementN)*>

III. Document Type Definition (DTD)

➤ Contenu vide

Un élément de contenu vide peut uniquement avoir des attributs. Les éléments vides sont souvent utilisés pour des liens entre éléments.

<!ELEMENT element EMPTY>

<!ATTLIST ref idref IDREF #REQUIRED>

```

1  <?xml version="1.0" encoding="windows-1252" standalone="no"?>
2  <!DOCTYPE examen SYSTEM "exam.dtd">
3  <examen code="coursXML">
4      <titre>Outils et documents XML</titre>
5      <date mois="sep" annee="2008" />
6      <questions>
7          <question><partie />contenu de la question<partie />gggd</question>
8          <question><partie />autre question</question>
9          <question><partie /> fff</question>
10         <question><partie /> fffhhh</question>
11         <question><partie /> ejjrb</question>
12     </questions>
13 </examen>

```

```

1  <!ELEMENT examen      (titre, date, questions) >
2  <!ELEMENT titre      (#PCDATA)>
3  <!ATTLIST examen
4      |      |      code NMTOKEN #REQUIRED>
5  <!ELEMENT date        EMPTY>
6  <!ATTLIST date
7      |      |      mois (jan|fev|mar|avr|mai|jun|jui|aou|sep|oct|nov|dec) #REQUIRED
8      |      |      annee NMTOKEN #REQUIRED>
9  <!ELEMENT questions   (question, question, question, question, question) >
10 <!ELEMENT question     (#PCDATA|partie)*>
11 <!ELEMENT partie       EMPTY>
12

```

III. Document Type Definition (DTD)

✓ Attributs

- Pour qu'un document soit valide, tout attribut présent dans la balise ouvrante d'un élément doit être déclaré.
- La déclaration d'un attribut prend la forme générale suivante :

<!ATTLIST *element* *attribut* **type default**>

Le type et la valeur par défaut de l'attribut

- Possibilité de déclarer plusieurs attributs en même temps pour un même élément

<!ATTLIST *element*

attribut1 type1 default1

attribut2 type2 default2

...

attributN typeN defaultN>

Le type d'un attribut détermine quelles sont ses valeurs possibles. Les DTD proposent uniquement un choix fini de types pour les attributs. Le type doit en effet être pris dans la liste suivante. Les types les plus utilisés sont CDATA, ID et IDREF.

CDATA

Ce type est le plus général. Il n'impose aucune contrainte à la valeur de l'attribut. Celle-ci peut être une chaîne quelconque de caractères.

(*value-1* | *value-2* | ... | *value-N*)

La valeur de l'attribut doit être un des jetons [Section 2.2.3] *value-1*, *value-2*, ... *value-N*. Comme ces valeurs sont des jetons, celles-ci ne sont pas délimitées par des apostrophes ' ' ou des guillemets ' " '.

NMTOKEN

La valeur de l'attribut est un jeton [Section 2.2.3].

NMTOKENS

La valeur de l'attribut est une liste de jetons séparés par des espaces.

ID

La valeur de l'attribut est un nom XML [Section 2.2.3]. Un élément peut avoir un seul attribut de ce type.

IDREF

La valeur de l'attribut est une référence à un élément identifié par la valeur de son attribut de type ID.

IDREFS

La valeur de l'attribut est une liste de références séparées par des espaces.

NOTATION

La valeur de l'attribut est une notation

ENTITY

La valeur de l'attribut une entité externe non XML

ENTITIES

La valeur de l'attribut une liste d'entités externes non XML

Réservés à l'usage des entités externes non XML

III. Document Type Definition (DTD)

XML distingue deux types d'identificateurs:

- ✓ **Les jetons** : Un *jeton* est une suite quelconque des caractères
Lettres minuscules et majuscules, les chiffres, les caractères ‘-’, ‘_’, ‘.’, ‘:’
- ✓ **Les noms XML** : Un nom XML est un jeton qui peut commencer par une lettre, un
les caractères ‘_’ et ‘.’. **Un nom XML ne peut pas commencer par un chiffre ou
par les caractères ‘-’ et ‘.’.**

III. Document Type Definition (DTD)

✓ Attributs

- **Attributs de type ID, IDREF et IDREFS**


Utilisés pour matérialiser les liens entre les données d'un document (*exemple : des références à d'autres parties du document*)

- ✓ Un attribut de type ID permet d'identifier de façon unique un élément du document. La valeur de cet attribut doit être unique dans tout le document. **Un seul attribut de type ID dans un document.**
- ✓ La valeur d'un attribut de type IDREF doit-être la valeur d'un attribut de type **ID** d'un (autre) élément pour que le document soit valide.
- ✓ La valeur d'un attribut de type IDREFS doit être une suite de noms séparés par des espaces. Chacun de ces noms doit, en outre, être la valeur d'un attribut de type **ID** d'un élément pour que le document soit valide.

III. Document Type Definition (DTD)

✓ Attributs

```
<?xml version="1.0" encoding="iso-8859-1" standalone="no"?>
<!DOCTYPE book [
  <!ELEMENT book      (section)*>
  <!ELEMENT section   (#PCDATA | ref | refs)*>
  <!ATTLIST section   id ID #IMPLIED>
  <!ELEMENT ref        EMPTY>
  <!ATTLIST ref        idref IDREF #REQUIRED>
  <!ELEMENT refs        EMPTY>
  <!ATTLIST refs       idrefs IDREFS #REQUIRED>
]>
<book>
  <section id="sec0">Une référence <ref idref="sec1"/></section>
  <section id="sec1">Des références <refs idrefs="sec0 sec2"/></section>
  <section id="sec2">Section sans référence</section>
  <section id="sec3">Une auto-référence <refs idrefs="sec3"/></section>
</book>
```

A blue arrow points from the `idref="sec1"` attribute in the first `<ref>` tag to the `id="sec1"` attribute in the second `<section>` tag. Both attributes are circled in blue.

III. Document Type Definition (DTD)

✓ Attributs

```
<?xml version="1.0" encoding="iso-8859-1" standalone="no"?>
<!DOCTYPE book [
  <!ELEMENT book      (section)*>
  <!ELEMENT section  (#PCDATA | ref | refs)*>
  <!ATTLIST section id ID #IMPLIED>
  <!ELEMENT ref      EMPTY>
  <!ATTLIST ref      idref IDREF #REQUIRED>
  <!ELEMENT refs     EMPTY>
  <!ATTLIST refs     idrefs IDREFS #REQUIRED>
]>
<book>
  <section id="sec0">Une référence <ref idref="sec1"/></section>
  <section id="sec1">Des références <refs idrefs="sec0 sec2"/></section>
  <section id="sec2">Section sans référence</section>
  <section id="sec3">Une auto-référence <refs idrefs="sec3"/></section>
</book>
```

III. Document Type Definition (DTD)

➤ **"value" ou 'value'**

La valeur *value* est une chaîne quelconque de caractères délimitée par des apostrophes `' '` ou des guillemets `" "`. Si l'attribut est absent pour un élément du document, sa valeur est implicitement la chaîne *value*.

➤ **#IMPLIED** : L'attribut est *optionnel* et il n'a pas de valeur par défaut. Si l'attribut est absent, il n'a pas de valeur.

➤ **#REQUIRED** : L'attribut est *obligatoire* et il n'a pas de valeur par défaut.

➤ **#FIXED "value" ou #FIXED 'value'** : La valeur *value* est une chaîne quelconque de caractères délimitée par des apostrophes `' '` ou des guillemets `" "`. La valeur de l'attribut est fixée à la valeur *value* donnée. Si l'attribut est absent, sa valeur est implicitement *value*. Si l'attribut est présent, sa valeur doit être *value* pour que le document soit valide.

III. Document Type Definition (DTD)

`<!ATTLIST tag meta CDATA "default">`

Attribut dans le document	Valeur
<code><tag meta="Hello World!"></code>	Hello World!
<code><tag></code>	Valeur par défaut default
<code><tag meta=""></code>	Chaîne vide
<code><tag meta="=='&quot;;=='></code>	== ' ' ==
<code><tag meta="'==&apos;;'"></code>	== ' ' ==
<code><tag meta="=='&lt;&amp;&gt;;=='></code>	==<&>==
<code><tag meta="=='&#60;&#38;&#62;=='></code>	==<&>==

`<!ATTLIST book lang (fr | en) "fr">`

Attribut dans le document	Valeur
<code><book></code>	Valeur par défaut fr
<code><book lang="fr"></code>	Valeur par défaut fr
<code><book lang="en"></code>	Jeton en
<code><book lang="de"></code>	<i>non valide</i> car la valeur de n'est pas énumérée

III. Document Type Definition (DTD)

`<!ATTLIST entry id ID #REQUIRED>`

Attribut dans le document	Valeur
<code><entry></code>	<i>non valide</i> attribut absent
<code><entry id="id-234"></code>	Nom id-234
<code><entry id="Hello World!"></code>	<i>non valide</i> car Hello World! n'est pas un nom

`<!ATTLIST xref ref IDREF #REQUIRED>`

Attribut dans le document	Valeur
<code><xref ref="id-234"/></code>	id-234
<code><xref ref="-id234"/></code>	<i>non valide</i> car -id234 n'est pas nom.

`<!ATTLIST xrefs refs IDREFS #REQUIRED>`

Attribut dans le document	Valeur
<code><xrefs refs="id-234"/></code>	Nom id-234
<code><xrefs refs="id-234 id-437"/></code>	Noms id-234 et id-437

Exercice 1 : Création d'un livre en XML

On souhaite proposer un document xml qui décrit les informations d'un livre. En effet, un livre est composé de sections (au moins 2), de chapitres (au moins 2) et de paragraphes (au moins 2). Le livre doit contenir la liste des auteurs. Chaque auteur a un nom et un prénom. Tous les éléments doivent posséder un titre, sauf le paragraphe qui contient du texte.

Travail à faire : Proposez une structuration XML de ce document. On oblige avoir : 2 auteurs, 2 sections, 2 chapitres par section et 2 paragraphes par chapitre.

Exercice 2 :

On souhaite compléter la structure du document XML de l'exercice précédent. On veut ajouter les attributs nom et prenom pour les auteurs. Aussi, donner l'attribut titre pour le livre, les sections et les chapitres.

1. Analysez la structure du nouveau document. Y a-t-il des simplifications possibles ?
2. Vérifiez, à l'aide de l'éditeur, que votre document est bien formé.

Exercice 1.

Rédiger une DTD pour une bibliographie. Cette bibliographie :
contient des livres et des articles ;

les informations nécessaires pour un livre sont :

- son titre général ;

- les noms des auteurs ;

- ses tomes et pour chaque tome, leur nombre de pages ;

- des informations générales sur son édition comme par exemple le nom de l'éditeur,
le lieu d'édition, le lieu d'impression, son numéro ISBN ;

les informations nécessaires pour un article sont :

- son titre ;

- les noms des auteurs ;

- ses références de publication : nom du journal, numéro des pages, année de
publication et numéro du journal

on réservera aussi un champ optionnel pour un avis personnel.

Soit le document XML ci-dessous. Ecrire la DTD validant ce document.

```
<?xml version="1.0"? encoding="UTF-8">
<options>
  <cours id="c1" titre="XML">
    <responsable>Med L.</responsable>
    <description>Ce cours permet de <objectif>découvrir le format XML</objectif> et
    <objectif>maitriser les langages liés à XML</objectif>. Prérequis : <prérequis>
    programmation Java</prérequis> et <prérequis>HTML</prérequis>
    </description>
    <séance no="1" date="15/12/2022">XML : les bases</séance>
    ...
  </cours>
  <cours id="c2" titre="Programmation en Python">
    <responsable>M. L</responsable>
    <description>...</description>
    <séance no="1" date="16/12/2022">Introduction</séance>
    ...
    <remarque>Enseignement en anglais</remarque>
  </cours>
  ...
  <étudiant numéro="n123456">
    <nom>Ali Mohamed</nom>
    <option cours="c1" note="15"/>
    ...
    <absence type="justifiée">22/12/2022</absence>
    ...
  </étudiant>
  ...
</options>
```